

Univerzita J. E. Purkyně

Přírodovědecká fakulta

Katedra informatiky

Počítačové zpracování signálu

ZS 2025/2026

Seminární práce I.

Johana Pribanová

Aplikovaná Informatika

Obsah


Odkaz na repositář s kódem	2
Výpočet tepové frekvence z EKG signálu	3
Postup řešení	4
Grafické výstupy	5
Výpočet korelace měřených signálů	7
Postup řešení	8
Grafické výstupy	9
Závěr	11
Použitá literatura	12

Odkaz na repozitář s kódem

<https://github.com/DZOUHAS29/PZS-Zapocty-Pribanova>

Výpočet tepové frekvence z EKG signálu

Zadání: Ve zdrojové databázi najdete celkem 17 měření EKG signálu. Signál je již filtrován a centralizován kolem podélné osy. EKG signál obsahuje dominantní peaky, které se nazývají R vrcholy. Vzdálenost těchto vrcholů určuje dobu mezi jednotlivými tepy. Počet tepů za minutu je tedy počet R vrcholů v signálu o délce jedné minuty. Navrhněte algoritmus, který bude automaticky detekovat počet R vrcholů v EKG signálech a prezentujte tepovou frekvenci při jednotlivých jízdách/měřeních. Váš algoritmus následně otestujte na databázi MIT-BIH <https://physionet.org/content/nsrdb/1.0.0/> a prezentujte jeho úspěšnost vzhledem k anotovaným datům z databáze.



Obrázek 1: Jedna perioda EKG signálu s dominantním R vrcholem.

Vstupní data: <https://physionet.org/content/drivedb/1.0.0/>

Testovací databáze: <https://physionet.org/content/nsrdb/1.0.0/>

Grafické výstupy: Graf zobrazující tepovou frekvenci v závislosti na měření. Grafické schéma, tabulky

Postup řešení


Nejprve jsem si z databáze DriveDB vytáhla signál useknutý na 1 minutu, jelikož zjišťujeme počet tepů za minutu. Limit jsem určila podle největšího vzorkování v signálech. Jelikož je každý signál jinak vzorkovaný, před použitím funkce `find_bpm()` jsem ho ještě omezila na 60 sekundový úsek.

Ve funkci `find_bpm()` si inicializuji časový vektor, pro vykreslení grafu. V měřeních je jeden signál, kde nám nejspíše vypadl sensor a před tím než dosáhne 60 sekund, máme pouze širokou flat line až do konce. Kvůli tomuto problému jsem se rozhodla celého úseku zbavit. Jako threshold pro odlehlé hodnoty jsem nastavila hodnoty, které mají o 2 jednotky více než střední hodnota. Dále pak pracuji se signály bez horních odlehlých hodnot.


Pro nalezení R-vrcholů jsem nejdříve použila konvoluci podle Gaussovi křivky, která je specifická svým vrchem a trochu mi připomíná jeden R-vrchol. Pro konvoluci používám metodu `gaussian_filter1d()` z knihovny `scipy.ndimage`. Metoda přijímá parametr `sigma`, která určuje míru vyhlazení. S tímto parametrem jsem si trochu pohrála, tak aby ze signálu zůstaly pouze dominantní R-peaky a menší peaky po nich. Poté jsem použila metodu `find_peaks()`, která hledá vrcholy signálu. Metoda přijímá parametry `prominence`, který definuje šířku pásma na ose `y` pro vybrání peaku, a `distance`, který rozdělí signál na okna podle osy `x`. S oběma parametry jsem si znovu dost pohrála pro dosažení výsledku, který se mi líbil. Nalezené vrcholy pak vykreslím do grafu. Metoda `find_bpm()` pak vrátí počet vrcholů, což nám říká jakou tepovou frekvenci řidič měl za minutu. Následně jsem pak všechny řidiče porovnávala ve sloupcovém grafu, našla průměrnou hodnotu a rozptyl hodnot.

Po vyzkoušení algoritmu na testovací databázi a porovnání s databázovými výsledky se sice objevily rozdíly, které vznikly především kvůli vyšší rozdílnosti velikostí R-vrcholů v signálech, ale v některých případech jsem se s tepovou frekvencí dost přiblížila, či dokonce trefila.

Grafické výstupy



Obrázek 3: Výstupní graf find_bpm() algoritmu EKG signálu řidiče č. 03 s vyznačenými R-peaky a výsledným tepem.



Obrázek 4: Sloupkový graf porovnávající tepové frekvence mezi řidiči s vypočítaným průměrem a rozptylem

	DB hodnota	Moje hodnota	Shoda
16265	96	95	99
16272	64	66	97
16273	94	94	100
16420	95	95	100
16483	99	97	98
16539	79	79	100
16773	155	75	48
16786	71	70	99
16795	125	70	56
17052	70	70	100
17453	84	83	99
18177	112	107	96
18184	90	88	98
19088	108	63	58
19090	107	102	95
19093	128	91	71
19140	105	104	99
19830	111	26	23

Obrázek 5: Tabulka porovnávající výsledky z testovací databáze NSRDB s mými výsledky

Výpočet korelace měřených signálů

Zadání: Ve zdrojové databázi najdete celkem 13 pacientů, kde se u každého měří celkem 3 signály (EKG, ABP a ICP). U každého z pacientů vypočítejte korelaci mezi jejich EKG, ABP a ICP signálem. Dále u všech pacientů proveďte korelace mezi jejich ABP signály. Před výpočty ověřte, že všechny signály mají stejnou vzorkovací frekvenci a jsou centralizovány podle podélné osy. V opačném případě převzorkujte všechny signály na Vámi zvolenou vzorkovací frekvenci. Pro smysluplné provedení korelační analýzy na ABP signálech je nutné nejprve srovnat signály na stejný počátek, nejlépe dle dominantního vrcholu. Vyhodnoťte vždy pouze prvního hodinu signálu. Pokud v signálech najdete chybějící data, proveďte jejich nahrazení například pomocí interpolace.



Obrázek 2: Dva signály EKG, které je nutné před analýzou centralizovat.

Vstupní data: <https://physionet.org/content/charisdb/1.0.0/>

Grafické výstupy: Míra shody mezi jednotlivými signály u jednoho pacienta, mapa míry shody mezi jednotlivými pacienty na signálu ABP. Tabulka s číselnými hodnotami míry shody.

Postup řešení

Jako první jsem si z databáze CharisDB vytáhla data naměřená v úseku 24 hodin. Jelikož se v datech vyskytovalo hodně odlehlých hodnot, nejspíše kvůli výpadku senzorů nebo změně polarity senzorů, tak jsem signály nejprve očistila od odlehlých hodnot, pak všechny nan hodnoty doplnila, zinterpolovala a poté srovnala na nulovou y osu. Jako poslední jsem signály zkorelovala a vytvořila grafy.

Funkce `normalizace_signalu()` se stará o celkové upravení signálu. Jako první vyfiltruji ze signálu nan hodnoty pro zjištění prvního a třetího kvartálu. Pro detekci odlehlých hodnot tentokrát používám robustnější metodu s použitím mezikvartálního rozpětí (IQR). Metoda je více odolnější na odlehlé hodnoty. Rovnice, kterou jsem použila je ze statistiky a vypadá následovně: horní hranice = $\text{třetí kvartál} + 1.5 * \text{IQR}$; dolní hranice = $\text{první kvartál} - 1.5 * \text{IQR}$. Parametrem 1.5 uvedeným před IQR, pak můžeme ovládat kolik hodnot označíme za odlehlé. Číslo 1.5 je často používáno ve statistice, lze upravovat, ale já jsem ho ponechala stejné. Pak jsem hodnoty, které překračovaly hranice smazala a následně celý signál zinterpolovala. Použila jsem základní lineární interpolaci, která spojí poslední bod před nan hodnotou a první bod po ní čarou. Také jsem doplnila hodnoty na začátek a konec, abych se zbavila všech nan hodnot. Poté jsem přepočítala první a třetí kvartál pro nově vzniklý signál a posunula ho na nulovou y osu s pomocí nového IQR a mediánu.

Jako další krok byl posunout signály na jejich první dominantní vrchol pro lepší vypočítání korelace. O to se stará funkce `posun_na_peaks()`. Tam nejprve zjistím vrcholy signálů stejným způsobem jako v předchozím zadání a pak signály na ně posunu. Poté zjistím, jaký signál je nejkratší a upravím podle něj i ostatní.


Když mám signály očištěné a posunuté, vložím je do tabulky a následně provedu korelaci. Korelaci jsem graficky zobrazila pomocí uzlového grafu, jelikož mi to přišlo velmi zajímavé a možná nestandardní. V grafu zobrazuji pozitivní korelaci modře a negativní červeně. Síla vztahu jde poznat podle tloušťky hrany. Korelace nám ukazuje jaký vztah mají proměnné mezi sebou. Pokud je korelace pozitivní číslo, znamená to, že obě hodnoty spolu rostou. Pokud je korelace záporná, znamená to, že když jeden signál roste, druhý klesá. Samotný korelační koeficient pak ukazuje jak silný tento vztah je.

Na závěr jsem pak vrátila z funkce ABP signál každého pacienta a zkorelovala dohromady s ostatními pacienty. Variační koeficienty ABP signálu mezi pacienty vyšly velice malé a proto o nich můžeme prohlásit, že jsou statisticky nevýznamné. Následně jsem také vykreslila tabulku všech hodnot pro lepší přehled.

Grafické výstupy

	ekg	abp	icp
ekg	1.000000	-0.095406	0.651213
abp	-0.095406	1.000000	-0.392454
icp	0.651213	-0.392454	1.000000


Obrázek 6: Korelační matice EKG, ABP a ICP signálů pacienta charis6.



Obrázek 7: Uzlový graf zobrazující korelaci mezi EKG, ABP a ICP signály.

	charis10	charis11	charis12	charis13	charis1	charis2	charis3	charis4	charis5	charis6	charis7	charis8	charis9
charis10	1.000000	-0.000871	0.013549	0.003120	0.006812	-0.000565	0.002938	-0.002291	-0.003152	0.000806	-0.003343	0.012249	-0.004204
charis11	-0.000871	1.000000	-0.000148	0.002298	0.008698	-0.004106	-0.000809	0.000343	0.005340	0.001068	-0.004832	0.004948	-0.006489
charis12	0.013549	-0.000148	1.000000	0.007079	-0.003274	0.004513	0.001374	0.005974	-0.000956	-0.017251	-0.005705	0.001191	-0.001152
charis13	0.003120	0.002298	0.007079	1.000000	-0.018482	0.001276	-0.003160	0.007772	0.004993	0.002045	-0.049309	0.009246	0.000246
charis1	0.006812	0.008698	-0.003274	-0.018482	1.000000	0.003702	-0.000584	-0.004730	0.010960	0.000377	0.017156	0.001365	0.002323
charis2	-0.000565	-0.004106	0.004513	0.001276	0.003702	1.000000	0.015882	0.000923	-0.015102	-0.005239	0.005844	-0.005505	-0.003964
charis3	0.002938	-0.000809	0.001374	-0.003160	-0.000584	0.015882	1.000000	0.006018	-0.000736	-0.008348	0.000325	-0.006691	-0.002423
charis4	-0.002291	0.000343	0.005974	0.007772	-0.004730	0.000923	0.006018	1.000000	0.006086	-0.000749	-0.002222	0.001541	0.001981
charis5	-0.003152	0.005340	-0.000956	0.004993	0.010960	-0.015102	-0.000736	0.006086	1.000000	0.000280	-0.000412	-0.000248	-0.002310
charis6	0.000806	0.001068	-0.017251	0.002045	0.000377	-0.005239	-0.008348	-0.000749	0.000280	1.000000	-0.001771	0.014253	0.000505
charis7	-0.003343	-0.004832	-0.005705	-0.049309	0.017156	0.005844	0.000325	-0.002222	-0.000412	-0.001771	1.000000	-0.004547	0.003865
charis8	0.012249	0.004948	0.001191	0.009246	0.001365	-0.005505	-0.006691	0.001541	-0.000248	0.014253	-0.004547	1.000000	-0.006786
charis9	-0.004204	-0.006489	-0.001152	0.000246	0.002323	-0.003964	-0.002423	0.001981	-0.002310	0.000505	0.003865	-0.006786	1.000000

Obrázek 8: Korelační matice ABP signálů mezi pacienty.



Obrázek 9: Heatmap graficky znázorňující korelační koeficienty mezi pacienty

Závěr

Během seminární práce jsem si mohla vyzkoušet, jak je možné použít matematické modely a výpočty pro zjištění různých informací o zdravotních stavech. Při vypracovávání práce jsem mohla i poznat, jak se signály mohou velice lišit a jak náchylné můžou být na externí události (výpadky senzorů, změna polarity senzorů, zatřesení senzoru apod.). Také jsem se dozvěděla, že je potřeba počítat v analýze s různou škálou nepředvídatelných hodnot a důležitost používání robustních metod. Nejvíce pozitivní pro mě bylo, jak se tato práce prolínala se statistikou a jak hodně mi pomohla v přípravě na teoretickou zkoušku z KMA/PAS. Celkově mě vypracování velmi bavilo, i když to byla ze začátku docela výzva.

Použitá literatura

- 1) Materiály k přípravě na zkoušku z KMA/PAS. Odkaz:

<https://docs.google.com/document/d/1XQCyFJW5FKkd17fKEFhv7FK9P2ZoebiXOkbTZzPk4Qs/edit?tab=t.0#heading=h.kb82pp5cda0p>