

Univerzita J. E. Purkyně

Přírodovědecká fakulta

Katedra informatiky

Počítačové zpracování signálu

ZS 2025/2026

Seminární práce II.

Johana Pribanová

Aplikovaná Informatika

Obsah


Odkaz na repozitář s kódem	2
Klasifikace zvukových záznamů	3
Postup řešení	4
Závěr	9
Použitá literatura	10

Odkaz na repozitář s kódem

<https://github.com/DZOUHAS29/PZS-Zapocty-Pribanova>

Klasifikace zvukových záznamů

Zadání: Ve zdrojové databázi najdete celkem 208 hlasových záznamů písmene a. Pomocí Vámi vybrané techniky v časové nebo frekvenční oblasti klasifikujte zvukové záznamy na dobré a patologické. V případě patologických poté klasifikujte jednotlivé poruchy. Jejich výčet najdete buď v hlavičkových souborech nebo v propisu databáze. Pro klasifikaci do jednotlivých skupin použijte veškeré techniky, které jste si v rámci kurzu osvojili včetně Fourierovy a keprální analýzy. Úspěšnost Vašeho postupu porovnejte s anotacemi, resp. rozřazením do skupin, které provedli experti, kteří data pořizovali.



Obrázek 1: dva zvukové záznamy z databáze VOICED s normálním a patologickým průběhem.

Grafické výstupy: Grafy demonstrující práci se signálem v časové nebo frekvenční oblasti, vizualizace klasifikace v prostoru nebo pomocí Vámi zvolených parametrů. Tabulka s úspěšností klasifikace na jednotlivé skupiny a patologické signály.


Postup řešení

Jako první jsem si načetla data ze zdrojové databáze Voiced a nahrála je do dvou seznamů. První seznam jsou záznamy z měření a druhý seznam je slovník s anotacemi z databáze, které obsahují hodnocení záznamů od profesionálů.

Poté jsem vytvořila funkci `analyze()`, která v parametrech bere záznam a bool hodnotu pro vykreslení grafů.


Krok jedna bylo vymazat plochý signál na začátku a na konci, který odpovídá tichu. Pro nalezení plochého signálu jsem použila funkci `diff()` z knihovny `numpy`, která počítá rozdíly mezi sousedními hodnotami. Pokud tento rozdíl se rovná nula v našem případě to znamená, že se jedná o plochou čáru. Po nalezení těchto hodnot, vyhledám jejich id a nastavím je na hodnotu `nan`.

V druhém kroku jsem se zaměřila na potenciální hodnoty `nan` uvnitř signálu. Celý signál jsem proto projela lineární interpolací, která spojí dva sousední body čarou. Jako finální úpravu signálu jsem odstranila `nan` hodnoty na začátku, tím se nám signál posunul na začátek osy `x` a odebrala jsem `nan` hodnoty na konci.




Obrázek 2: Vycištěný signál od počátečních a konečných plochých čar a `nan` hodnot.

Další přichází Fourierova transformace. Fourierova transformace nám umožňuje zobrazit jaké frekvence v signálu jsou dominantní. Jelikož transformace nám může vrátit na začátku a konci prudké skoky, které vytváří umělý šum, použila jsem při vytváření tzv. Hammingovo okno, které tyto skoky potlačí na nulu. Výsledný signál jsem dala do absolutní hodnoty, abych dostala amplitudy frekvencí, tudíž jak každá frekvence je silná. Tyto frekvence pak odpovídají různým tónům z nahrávky. To nám umožňuje v praxi například odstranit z nahrávky vysoký pískavý tón. Transformaci jsem v tomto projektu ale použila pro vygenerování Kepstrálního signálu. I tak nám graf dává menší grafický náhled na to, jak se zdravý hlas liší od nemocného. Zatímco zdravý hlas má graf s čistšími a špičatými peaky, nemocný má více signál zašumělý.




Obrázek 3: Ukázka grafu Fourierovi transformace zdravého hlasu.




Obrázek 4: Ukázka grafu Fourierovi transformace nemocného hlasu.

Po získání Fourierovi transformace jsem vytvořila Kepstrální signál. Kepstrální analýza je metoda, která nám umožňuje zvýraznit opakující se signály od ostatních a oddělit tak zdroje zvuku. V tomto projektu ji využívám pro analýzu, jestli je samohláska vyslovována čistě nahlas nebo ne. Pro vytvoření signálu vezmu amplitudy z Fourierovi transformace a zlogaritmuji je. Logaritmus nám pak převede signál do podoby, kde se mezi sebou zdroje zvuků sčítají a následně to celé projedu inverzní Fourierovou transformací. Výsledek nám vrátí signál, který znázorňuje změny v průběhu mluvení a je definován v tzv. quefreny, jelikož se nevracíme úplně přesně zpět do původního času. Quefreny je definována jako $1/\text{frekvence}$. Pro mojí analýzu vybírám ze signálu interval od 20 - 135 Hz, což je oblast, která odpovídá mluvy u lidského hlasu. V grafu můžeme poté vidět několik vysokých a nízkých peaků. Vysoké peaky odpovídají vyslovování a nízké peaky odpovídají zvukům, které

nastávají s mlouvou (př. zvuky z krku, nosu apod.). Pokud máme signál, kde je největší peak viditelně vyšší a špičatý, indikuje to zdravý hlas, jelikož člověk vyslovuje samohlásku čistě a jasně. Pokud jsou peaky nízké znamená to, že je hlas nemocný, jelikož mluvu doprovází různé zvuky způsobené nemocí. Proto pro detekci zdravých a patologických signálů používám hodnotu v tomto dominantním vrcholu. Pokud hodnota překračuje hodnotu 0.4 hlas je zdravý, jinak ho hodnotím jako patologický. Hodnotu 0.4 jsem použila po analýze vrcholů několika signálů a od oka zprůměrovala.




Obrázek 5: Ukázka grafu Kepstrálního signálu zdravého hlasu.




Obrázek 6: Ukázka grafu Kepstrálního signálu patologického hlasu.

Jako poslední krok v analýze musím jednotlivé patologické signály rozdělit do skupin podle nemoci. Na tento krok jsem použila tzv. Spektrogram. Spektrogram je vizuální reprezentace spektra signálu v čase. U zdravého hlasu má spektrogram relativně stabilní čáry, které mezi sebou mají tmavší barvu a nejsou zašumělé. Jedním ze znaků nemocného hlasu pak může být zašumělý graf nebo vlnící se čáry.



Obrázek 6: Spektrogram zdravého hlasu.



Obrázek 7: Spektrogram nemocného hlasu.

Ze spektrogramu je možné vrátit hodnotu px , která reprezentuje matici hodnot, kde sloupce určují časový úsek. Tyto časové úseky pak procházím a hledám v nich největší hodnotu. Z těchto dominantních frekvencí spočítám směrodatnou odchylku. Směrodatná odchylka mi říká, jak moc jsou hodnoty daleko od střední, tedy jak moc hlas přeskakuje. Pokud je směrodatná odchylka nízká, hlas je stabilní, pokud je vysoká, hlas skáče, což nám může pomoci identifikovat křečovou dysfonii (hyperkinetic dysphonia), která vzniká staženými svaly v hrtanu a hlas tak není moc stabilní. Pro identifikování mezi refluxní laryngitidou (reflux laryngitis) a hypokinetic dysfonií (hypokinetic dysphonia) vypočítám energii signálu. To dosáhnu jednoduchou sumou matice px . Energie nám pak

odpovídá hlasitosti hlasu. Pokud tedy je hlas relativně stabilní a není tichý, identifikuji ho jako refluxní laryngitidu. Jako hypokinetickou dysfonii беру signály, které jsou stabilní, ale tiché. V podmínkách pro rozlišení mezi patologickými signály jsem zkoušela různé parametry, u který jsem následovně porovnávala úspěšnost.

Nakonec jsem výsledky dala do tabulky, porovnála s anotací a přidala sloupec „match”. Pokud se shodují je hodnota v sloupci 1 pokud ne 0.

	diagnoza	healthy	anotace	cpp	instability	hlasitost	match
voice001	hyperkinetic dysphonia	0	hyperkinetic dysphonia	0.25	249.59	0.37	1
voice002	healthy	1	healthy	0.55	156.41	1.83	1
voice003	healthy	1	hyperkinetic dysphonia	0.42	21.28	1.46	0
voice004	hypokinetic dysphonia	0	hypokinetic dysphonia	0.32	4.76	0.06	1
voice005	healthy	1	hypokinetic dysphonia	0.46	13.95	0.75	0
...	...	...	...	...	...	...	...
voice204	healthy	1	healthy	0.40	307.52	0.47	1
voice205	hyperkinetic dysphonia	0	hyperkinetic dysphonia	0.23	173.80	1.15	1
voice206	healthy	1	healthy	0.48	64.44	2.37	1
voice207	reflux laryngitis	0	healthy	0.30	7.71	0.95	0
voice208	hyperkinetic dysphonia	0	hyperkinetic dysphonia	0.33	100.67	2.23	1

208 rows x 7 columns

Obrázek 8: Tabulka výsledků funkce analyze().

I přes dlouhé ladění parametrů pro rozdělení signálů a testování jiných metod pro analýzu (př. vypočítání šumu apod.) mají moje výsledky úspěšnost 35%.

	not matched	matched
moje vysledky	135	73
uspesnost		35%

Obrázek 9: Tabulka výsledků porovnané s anotací.

Závěr

Tato seminární práce byla pro mě trochu větší výzva než ta předešlá, hlavně protože se mi nepodařilo, i přes vyzkoušení několika různých metod a nápadů, dosáhnout větší přesnosti. Díky úloze jsem si ale mohla rozšířit obzory v oblasti matematiky a také trochu v oblasti medicíny. Na práci mě nejvíce bavila praktičnost úlohy a studie, kde všude se dá Fourierova transformace a keprální analýza využít. Zároveň mám veliký respekt k profesionálům, kteří s těmito signály denně pracují a nachází různé algoritmy pro jejich řešení, jelikož to není vůbec nic jednoduchého.

Použitá literatura

- 1) Youtube video vysvětlující Fourierovu transformaci:
<https://www.youtube.com/watch?v=spUNpyF58BY>
- 2) Youtube video vysvětlující Kepstrální analýzu:
<https://www.youtube.com/watch?v=TmNo18IFgkM>